

Extraction automatique d'informations environnementales à partir d'articles scientifiques

Thibault Schneeberger
QARMA, LIS

Valentin Emiya
QARMA, LIS
valentin.emiya@lis.fr

Constance Douwes
QARMA, LIS
constance.douwes@lis.fr

thibault.schneeberger@proton.me

1 Introduction et état de l'art

L'essor des modèles d'apprentissage profond à grande échelle a engendré une préoccupation croissante quant à leur impact environnemental. Dès 2019, [Strubell et al. \(2019\)](#) ont attiré l'attention de la communauté du traitement automatique des langues en quantifiant les coûts financiers et environnementaux de l'entraînement de modèles comme BERT et Transformer, révélant des empreintes carbone comparables à celles de vols transatlantiques.

Depuis, plusieurs travaux ont affiné ces estimations. [Patterson et al. \(2021\)](#) ont analysé l'énergie consommée par des modèles majeurs (T5, GPT-3, Switch Transformer) et montré que le choix du centre de données, de la localisation géographique et du matériel peut réduire l'empreinte carbone d'un facteur 100 à 1000. [Luccioni et al. \(2023\)](#) ont proposé une méthodologie complète pour estimer l'empreinte carbone du modèle BLOOM (176 milliards de paramètres) sur l'ensemble de son cycle de vie, de la fabrication du matériel au déploiement, aboutissant à une estimation de 25 à 50 tonnes de CO₂eq.

Malgré ces avancées méthodologiques, les informations relatives à l'impact environnemental restent dispersées dans les articles scientifiques et difficiles à collecter systématiquement. Certaines bases de données ont été constituées manuellement : Epoch.ai ([Epoch AI, 2025](#)) recense plus de 3000 modèles notables avec leurs caractéristiques techniques (nombre de paramètres, puissance de calcul, matériel), tandis que GreenMIR ([Kaila and Holzapfel, 2024](#)) catalogue la présence d'informations environnementales dans les publications du domaine audio (ISMIR). Cependant, ces efforts manuels ne permettent pas de suivre l'ensemble des modèles publiés de façon ex-

haustive et pérenne.

L'objectif de ce projet est d'automatiser l'extraction d'informations liées à l'impact environnemental des modèles d'apprentissage automatique directement à partir des articles scientifiques. Les approches d'extraction d'information ont été largement étudiées ([Abdullah et al., 2023](#)), et les méthodes génératives basées sur des grands modèles de langage (LLM) se révèlent actuellement les plus performantes ([Zhang et al., 2025](#)), surpassant les approches extractives classiques de type BERT ([Gardazi et al., 2025](#)).

Nous présentons dans ce rapport un système d'extraction automatique, ainsi qu'une évaluation permettant de mesurer la qualité des extractions par rapport aux données de référence d'Epoch.ai et GreenMIR.

2 Approches Préliminaires

Avant d'aboutir à l'architecture finale, nous avons exploré qualitativement plusieurs approches d'extraction d'information.

Expressions régulières. La première approche a été l'utilisation d'expressions régulières pour capturer des motifs numériques et textuels. Pour des raisons évidentes de complexité et de robustesse face à la variabilité des formulations scientifiques, cette méthode a été rapidement abandonnée.

Modèles extractifs. Nous avons testé un modèle RoBERTa réentraîné sur SQuAD v2, où la description de l'information à extraire était fournie en question et le modèle retournait un extrait de texte. L'avantage majeur est l'absence d'hallucination puisque le texte extrait provient directement du document. Cependant, même avec des modèles à grand contexte, il était difficile de faire correspondre les informations entre plusieurs sec-

tions du texte, le contexte se limitant souvent à un ou deux paragraphes (voir annexe A).

Génération augmentée par récupération.

Nous avons réalisé quelques tests avec des systèmes de type RAG. L'information étant parfois diffuse dans le texte, il était difficile de discriminer les passages pertinents pour la récupération.

Grands modèles de langage sur GPU local.

Nous avons testé des LLM en mode sans exemples préalables sur le cluster GPU, équipé de cartes NVIDIA A100 de 40 à 48 Go. La mémoire requise croît de façon quadratique avec la taille du contexte. Dans notre cas, le contexte est l'intégralité du texte du papier scientifique, soit plusieurs dizaines de milliers de tokens. Les modèles comme Mistral ou Llama étaient inaccessibles à cette échelle en raison de leur taille trop élevée. Nous avons testé Gemma 3 E4B et GPT-OSS 20B via Ollama et la bibliothèque Transformers, mais les résultats n'étaient pas satisfaisants en raison d'hallucinations fréquentes.

API Gemini 3 Flash. Nous nous sommes finalement tournés vers l'API Gemini 3 Flash, qui offre un contexte suffisamment grand, jusqu'à un million de tokens, et des performances supérieures à toutes les approches précédentes.

3 Architecture et Méthodologie

Le système d'extraction se décompose en trois étapes principales : la préparation des données, l'extraction par modèle de langage, et l'évaluation des résultats.

3.1 Préparation des données

La première étape consiste à constituer une base de données SQLite à partir des jeux de données de référence. Pour chaque papier, nous récupérons le document PDF depuis son URL, puis en extrayons le texte brut. Les informations sont organisées en plusieurs tables :

- **paper_info** : métadonnées du papier, incluant le lien vers le PDF
- **paper_document** : contenu binaire du PDF téléchargé
- **paper_text** : texte extrait du document

- **model_info** : informations de référence sur les modèles, servant de vérité terrain

Deux tables de référence sont également constituées : une table des pays avec leur intensité carbone en gCO₂/kWh, et une table du matériel avec sa puissance de calcul et sa consommation (voir annexe B pour le schéma complet).

3.2 Stratégie d'extraction

L'extraction se déroule en deux phases. Dans un premier temps, le modèle de langage reçoit le texte intégral du papier et doit énumérer tous les modèles mentionnés. La réponse attendue est une liste Python de noms de modèles.

Dans un second temps, pour chaque modèle identifié, une série de questions est posée afin d'extraire les attributs suivants :

- Nombre de paramètres
- Type de matériel utilisé pour l'entraînement
- Nombre d'unités matérielles (GPUs)
- Puissance unitaire du GPU (kW)
- Performance de calcul unitaire du GPU (FLOP/s)
- Durée d'entraînement en heures
- Puissance de calcul totale en FLOP
- Pays d'entraînement
- Année de publication
- Émissions de CO₂ équivalent

Pour chaque question, le modèle doit retourner une liste contenant deux éléments : la valeur extraite et une citation du passage source justifiant cette réponse. Cette structure permet de tracer l'origine de chaque information et de détecter d'éventuelles hallucinations.

3.3 Évaluation

L'évaluation compare les informations extraites aux données de référence en deux phases.

Appariement des entités. Les modèles inférés sont d'abord appariés aux modèles de référence par similarité de nom, en utilisant la distance de Jaro-Winkler. Cet appariement permet de distinguer trois cas : les modèles correctement détectés, les modèles manqués et les modèles hallucinés.

Notation des champs. Pour chaque paire de papiers et paire appariée de modèles, une distance est calculée par champ selon sa nature, de façon à ce qu'elle soit comprise entre 0 et 1 :

- **Valeurs numériques** : erreur relative symétrique, définie par :

$$\frac{|v_{inf} - v_{ref}|}{\max(|v_{inf}|, |v_{ref}|)}$$

- **Identifiants** : correspondance binaire, définie par :

$$\begin{cases} 1 & \text{si } v_{inf} = v_{ref} \\ 0 & \text{sinon} \end{cases}$$

- **Chaines de caractères** : Jaro-Winkler agnostique à l'ordre des mots.
- **Année** : erreur absolue normalisée sur 5 ans, définie par :

$$\frac{|v_{inf} - v_{ref}|}{5}$$

Ces distances sont ensuite agrégées pour calculer des métriques de précision et rappel souples, prenant en compte à la fois la qualité de l'extraction et les pénalités pour les modèles hallucinés.

4 Expérimentations et Résultats

Deux expériences ont été réalisées pour évaluer le système d'extraction.

4.1 Protocole expérimental

GreenMIR. La première expérience porte sur l'intégralité du jeu de données GreenMIR, soit 113 papiers issus de la conférence ISMIR contenant chacun un modèle annoté. Ce jeu de données est centré sur les modèles de traitement audio et musical, avec un accent particulier sur la documentation de l'impact environnemental. L'extraction est réalisée dans deux modes : *strict*, où seules les valeurs explicitement mentionnées dans le texte sont extraites, et *derived*, où le LLM est autorisé à déduire des valeurs à partir du contexte.

Epoch.ai. La seconde expérience porte sur un sous-ensemble du jeu de données Epoch.ai. Le jeu complet contenant plus de 3000 modèles, son traitement intégral aurait nécessité

un nombre de jetons trop important. Nous avons donc sélectionné un échantillon de 111 papiers contenant 150 modèles, accessibles via ArXiv. L'extraction est également réalisée en mode *derived*.

4.2 Métriques d'évaluation

L'évaluation repose sur deux niveaux de granularité : l'appariement des entités et la qualité d'extraction des champs.

Métriques d'appariement. L'appariement permet de mesurer la capacité du système à détecter les bons modèles. Après appariement par similarité Jaro-Winkler sur le nom du modèle et distance relative sur le nombre de paramètres, on distingue :

- **TP** : modèles de référence correctement appariés à un modèle inféré
- **FN** : modèles de référence non détectés (oublis)
- **FP** : modèles inférés sans correspondance (hallucinations)
- **TN** : les vrais négatifs ne sont pas comptabilisés, l'ensemble des modèles absents d'un papier étant par nature infini

Les métriques classiques sont alors calculées :

$$\text{Précision} = \frac{TP}{TP + FP} \quad (1)$$

$$\text{Rappel} = \frac{TP}{TP + FN} \quad (2)$$

$$F1 = \frac{2 \times \text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}} \quad (3)$$

Métriques catégorielles. Pour chaque champ, les mêmes définitions de TP, FP et FN sont appliquées au niveau des attributs extraits : un TP correspond à une valeur correctement détectée, un FP à une valeur inférée sans correspondance dans la vérité terrain, et un FN à une valeur de référence non extraite. Les métriques de précision, rappel et F1 sont calculées de la même manière que pour l'appariement.

Métriques de distances. Pour chaque champ, on définit un score de similarité $S = 1 - d$, où d est la distance calculée selon le type de champ. On calcule ensuite des métriques souples qui prennent en compte la qualité des

valeurs extraites, au-delà de leur simple présence :

$$\text{Précision alignée} = \frac{\sum_{i \in TP} S_i}{TP} \quad (4)$$

$$\text{Précision globale} = \frac{\sum_{i \in TP} S_i}{TP + FP} \quad (5)$$

$$\text{Rappel souple} = \frac{\sum_{i \in TP} S_i}{TP + FN} \quad (6)$$

La précision globale pénalise les hallucinations en les comptant comme des erreurs totales dans le dénominateur. Le score F1 souple global est la moyenne harmonique de la précision globale et du rappel souple :

$$\text{F1 souple} = \frac{2 \times \text{Précision globale} \times \text{Rappel souple}}{\text{Précision globale} + \text{Rappel souple}} \quad (7)$$

4.3 Résultats

Appariement des modèles. Les papiers du jeu GreenMIR contenant chacun un seul modèle, l'appariement est trivial et n'est pas reporté ici. Sur Epoch.ai en revanche, les papiers contiennent souvent plusieurs modèles, ce qui rend l'appariement non trivial. Le tableau 1 présente les résultats.

Appariés	GT	Inférés	P	R	F1
149	150	203	0.734	0.993	0.844

TABLE 1 – Métriques d'appariement des entités sur Epoch.ai (mode derived).

Métriques catégorielles. Les tableaux 2, 3 et 4 présentent les métriques catégorielles de présence par champ. Ces métriques évaluent la capacité du système à détecter la présence d'une information, indépendamment de la qualité de la valeur extraite.

Métriques de distances. Les tableaux 5, 6 et 7 détaillent les métriques de distances pour chaque attribut. Ces métriques évaluent la qualité des valeurs extraites en tenant compte de la proximité entre la valeur inférée et la valeur de référence.

4.4 Analyse

Appariement des entités. Sur Epoch.ai, le rappel est excellent (99.3%) mais la précision est plus faible (73.4%), due au grand nombre

Champ	TP	FP	FN	P	R	F1
Année	6	0	107	1.000	0.053	0.101
Paramètres	5	0	8	1.000	0.385	0.556
Pays	10	0	70	1.000	0.125	0.222
Matériel	5	0	34	1.000	0.128	0.227
FLOP	–	–	–	–	–	–
Durée entr.	8	0	18	1.000	0.308	0.471
CO ₂ eq	–	–	–	–	–	–
Nb. unités	13	0	27	1.000	0.325	0.491
Énergie	–	–	–	–	–	–
FLOP/s	–	–	–	–	–	–
Moy.	–	–	–	1.000	0.221	0.345

TABLE 2 – Métriques catégorielles par champ sur GreenMIR (mode strict).

Champ	TP	FP	FN	P	R	F1
Année	68	3	45	0.958	0.602	0.739
Paramètres	12	2	1	0.857	0.923	0.889
Pays	13	0	67	1.000	0.163	0.280
Matériel	21	1	18	0.955	0.538	0.689
FLOP	–	–	–	–	–	–
Durée entr.	19	1	7	0.950	0.731	0.826
CO ₂ eq	–	–	–	–	–	–
Nb. unités	29	2	11	0.935	0.725	0.817
Énergie	–	–	–	–	–	–
FLOP/s	–	–	–	–	–	–
Moy.	–	–	–	0.943	0.614	0.707

TABLE 3 – Métriques catégorielles par champ sur GreenMIR (mode derived). P : précision, R : rappel.

Champ	TP	FP	FN	P	R	F1
Année	121	43	29	0.738	0.807	0.771
Paramètres	114	40	13	0.740	0.898	0.811
Pays	37	11	112	0.771	0.248	0.376
Matériel	53	24	27	0.688	0.663	0.675
FLOP	5	1	64	0.833	0.072	0.133
Durée entr.	8	11	12	0.421	0.400	0.410
CO ₂ eq	–	–	–	–	–	–
Nb. unités	44	27	17	0.620	0.721	0.667
Énergie	1	0	79	1.000	0.013	0.025
FLOP/s	1	1	67	0.500	0.015	0.029
Moy.	–	–	–	0.701	0.426	0.433

TABLE 4 – Métriques catégorielles par champ sur Epoch.ai (mode derived).

Champ	n	P _a	P _g	R _s	F1 _s
Année	113	0.053	1.000	0.053	0.101
Paramètres	13	0.357	0.929	0.357	0.516
Pays	80	0.125	1.000	0.125	0.222
Matériel	39	0.103	0.800	0.103	0.182
FLOP	–	–	–	–	–
Durée entr.	26	0.206	0.670	0.206	0.315
CO ₂ eq	–	–	–	–	–
Nb. unités	40	0.325	1.000	0.325	0.491
Énergie	–	–	–	–	–
FLOP/s	–	–	–	–	–
Moy.	–	0.195	0.900	0.195	0.305

TABLE 5 – Métriques de distances par champ sur GreenMIR (mode strict). n : nombre d'exemples évalués.

Champ	n	P _a	P _g	R _s	F1 _s
Année	113	0.589	0.938	0.589	0.724
Paramètres	14	0.802	0.802	0.864	0.832
Pays	80	0.150	0.923	0.150	0.258
Matériel	39	0.410	0.727	0.410	0.525
FLOP	—	—	—	—	—
Durée entr.	26	0.475	0.617	0.475	0.537
CO ₂ eq	—	—	—	—	—
Nb. unités	41	0.707	0.935	0.725	0.817
Énergie	—	—	—	—	—
FLOP/s	—	—	—	—	—
Moy.	—	0.522	0.824	0.536	0.616

TABLE 6 – Métriques de distances par champ sur GreenMIR (mode derived). P_a : précision alignée, P_g : précision globale, R_s : rappel souple, F1_s : F1 souple.

Champ	n	P _a	P _g	R _s	F1 _s
Année	150	0.799	0.730	0.799	0.763
Paramètres	132	0.707	0.606	0.735	0.665
Pays	149	0.215	0.667	0.215	0.325
Matériel	80	0.312	0.325	0.312	0.318
FLOP	70	0.035	0.407	0.035	0.065
Durée entr.	30	0.261	0.413	0.392	0.402
CO ₂ eq	—	—	—	—	—
Nb. unités	75	0.505	0.533	0.621	0.574
Énergie	80	0.013	1.000	0.013	0.025
FLOP/s	68	0.001	0.034	0.001	0.002
Moy.	—	0.316	0.524	0.347	0.349

TABLE 7 – Métriques de distances par champ sur Epoch.ai (mode derived).

de modèles supplémentaires inférés (54 modèles “extra”). GreenMIR ne contenant qu’un modèle par papier, l’appariement y est trivial.

Détection de présence (métriques catégorielles). En mode strict sur GreenMIR, la précision catégorielle est systématiquement de 1.000 (aucun faux positif), le système n’extrayant que les valeurs explicitement présentes. En contrepartie, le rappel est très bas (F1 moyen = 0.345), ce qui confirme que la majorité des informations ne sont pas mentionnées de manière littérale dans les articles. Le passage en mode derived améliore significativement le rappel (F1 moyen = 0.707 sur GreenMIR), au prix de quelques faux positifs.

Sur Epoch.ai, les FP sont plus nombreux en raison des 54 modèles inférés en excès, ce qui réduit la précision catégorielle (F1 moyen = 0.433). Les champs les mieux détectés sont les paramètres (F1 = 0.889 sur GreenMIR derived, 0.811 sur Epoch) et la durée d’entraînement (F1 = 0.826 sur GreenMIR derived). À l’inverse, le pays d’entraînement souffre d’un rappel très faible (16% sur GreenMIR, 25%

sur Epoch), et l’énergie consommée ainsi que les FLOP/s du matériel ne sont quasi jamais détectés (F1 < 0.03).

Qualité des valeurs (métriques de distances). Les métriques de distances permettent d’évaluer non seulement si une valeur est détectée, mais aussi sa proximité avec la référence. Les attributs les mieux extraits en termes de qualité sont :

- Le nombre de paramètres (F1_s = 0.832 sur GreenMIR derived, 0.665 sur Epoch)
- Le nombre d’unités de calcul (F1_s = 0.817 sur GreenMIR derived, 0.574 sur Epoch)
- L’année de publication (F1_s = 0.724 sur GreenMIR derived, 0.763 sur Epoch)

Les attributs les plus difficiles sont :

- L’énergie consommée et les FLOP/s du matériel (F1_s < 0.03 sur Epoch, 0 sur GreenMIR)
- Le pays d’entraînement, avec un rappel souple très faible (15% sur GreenMIR, 21% sur Epoch)
- Les FLOP d’entraînement, rarement mentionnés explicitement (F1_s = 0.065 sur Epoch)

On observe un écart notable entre les métriques catégorielles et les métriques de distances pour certains champs. Par exemple, le pays d’entraînement obtient un F1 catégoriel de 0.280 sur GreenMIR derived (les quelques détections sont correctes en présence) mais un F1_s de seulement 0.258 (les valeurs détectées ne correspondent pas toujours au bon pays). À l’inverse, les paramètres montrent peu d’écart (F1 = 0.889 vs F1_s = 0.832), indiquant que les valeurs extraites sont généralement proches de la référence.

Différences entre datasets. GreenMIR présente une meilleure précision car les papiers ISMIR sont plus homogènes et contiennent des informations d’entraînement plus standardisées. Epoch.ai, couvrant un spectre plus large de modèles ML, présente plus de variabilité dans la façon dont les informations sont reportées, ce qui explique à la fois le plus grand nombre de faux positifs et les scores de distances plus faibles.

5 Discussion et Limitations

5.1 Estimation de l’empreinte carbone par calcul

L’empreinte carbone de l’entraînement d’un modèle (CO₂eq) n’est quasiment jamais reportée directement dans les articles scientifiques : aucun des 113 modèles de GreenMIR et aucun des 3 239 modèles d’Epoch.ai ne possède cette annotation dans la vérité terrain. Cette valeur ne peut donc être obtenue que par calcul, selon la formule :

$$\text{CO}_2\text{eq} = \text{PUE} \times P_{\text{gpu}} \times T \times N \times \text{CI} \quad (8)$$

où PUE est le coefficient d’efficacité énergétique du datacenter, P_{gpu} la puissance d’un GPU (kW), T la durée d’entraînement (h), N le nombre d’GPUs, et CI l’intensité carbone du réseau électrique du pays d’entraînement (gCO₂/kWh).

Disponibilité des champs dans la vérité terrain. Même dans la vérité terrain, la disponibilité conjointe de ces quatre champs est faible. Sur GreenMIR, seuls 13 modèles sur 113 (11,5%) possèdent simultanément le pays, le matériel (avec puissance connue dans la table de référence), la durée d’entraînement et le nombre d’unités. Sur Epoch.ai, cette proportion est de 12,3% (398 sur 3 239 modèles au total, 17 sur les 149 modèles de notre échantillon). Le tableau 8 résume la couverture individuelle de chaque champ dans la vérité terrain de notre échantillon.

Champ	GreenMIR	Epoch
Pays (CI disponible)	70,8%	99,3%
Matériel (puissance connue)	37,2%	53,0%
Durée d’entraînement	23,0%	13,4%
Nombre d’unités	35,4%	40,3%
Tous les champs	11,5%	11,4%

TABLE 8 – Disponibilité des champs nécessaires au calcul du CO₂eq dans la vérité terrain.

Couverture conjointe dans l’extraction.

La capacité du système à fournir simultanément les quatre champs nécessaires est encore plus limitée. La puissance unitaire du matériel (P_{gpu}) n’est quasiment jamais extraite directement (rappel catégoriel < 1%). En adoptant une approche *proxy* — identifier le matériel puis retrouver sa puissance dans une table de référence —, la couverture conjointe des

quatre champs dans l’inférence atteint 3,3% sur GreenMIR (mode derived) et 2,0% sur Epoch. Si l’on restreint aux cas où la vérité terrain et l’inférence sont toutes deux disponibles, on obtient respectivement 2,2% et 0,7%. Seul 1 modèle sur 91 (1,1%) sur GreenMIR derived présente une couverture proxy fiable (toutes les distances $\leq 0,5$), et aucun sur Epoch.

Propagation des erreurs. Même lorsque tous les champs sont présents, la qualité du CO₂eq calculé dépend de la précision de chaque composante. L’équation (8) étant un produit, l’erreur relative se propage de manière quadratique :

$$\frac{\delta \text{CO}_2\text{eq}}{\text{CO}_2\text{eq}} \approx \sqrt{\left(\frac{\delta P}{P}\right)^2 + \left(\frac{\delta T}{T}\right)^2 + \left(\frac{\delta N}{N}\right)^2 + \left(\frac{\delta \text{CI}}{\text{CI}}\right)^2} \quad (9)$$

En utilisant les distances moyennes observées comme proxy de l’erreur relative par champ, l’erreur combinée est de l’ordre de 43% sur GreenMIR derived et 56% sur Epoch. À cela s’ajoute l’incertitude sur le PUE, qui n’est jamais mentionné dans les articles et doit être supposé (typiquement entre 1,1 et 1,2), ajoutant une incertitude systématique d’environ 10%.

Avec les performances actuelles du système, la capacité à déduire un CO₂eq exploitable est quasi nulle.

6 Conclusion

Ce travail a présenté un système d’extraction automatique d’informations environnementales à partir d’articles scientifiques, évalué sur les jeux de données GreenMIR et Epoch.ai. Les résultats montrent que le système détecte efficacement les modèles (F1 d’appariement de 0,844 sur Epoch) et extrait correctement certains attributs bien documentés comme le nombre de paramètres (F1 catégoriel de 0,889 sur GreenMIR derived) ou le nombre d’unités de calcul (F1 = 0,817). En revanche, les informations rarement explicites dans les articles — pays d’entraînement, puissance du matériel, FLOP d’entraînement — restent largement hors de portée du système.

L’analyse de la faisabilité du calcul du CO₂eq révèle une limitation structurelle : même dans la vérité terrain, seuls 11% des modèles disposent de l’ensemble des champs né-

cessaires, et la couverture conjointe dans l'extraction est quasi nulle. Améliorer l'estimation de l'empreinte carbone nécessiterait à la fois un meilleur rappel sur les champs et une documentation plus systématique de ces informations par les auteurs d'articles.

References

- M. H. A. Abdullah, N. Aziz, S. J. Abdulkadir, H. S. A. Alhussian, and N. Talpur. 2023. [Systematic Literature Review of Information Extraction From Textual Data: Recent Methods, Applications, Trends, and Challenges](#). *IEEE Access*, 11 :10535–10562.
- Epoch AI. 2025. [Data on AI Models](#). Accessed : 2025-12-13.
- N. M. Gardazi, A. Daud, M. K. Malik, A. Bukhari, T. Alsahfi, and B. Alshemaimri. 2025. [BERT applications in natural language processing: a review](#). *Artificial Intelligence Review*, 58(166).
- Anna-Kristin Kaila and Andre Holzapfel. 2024. [Green MIR data table 2024](#). International Society for Music Information Retrieval Conference (ISMIR), San Francisco, California, USA.
- A. S. Luccioni, S. Viguier, and A.-L. Ligozat. 2023. [Estimating the Carbon Footprint of BLOOM, a 176B Parameter Language Model](#). *Journal of Machine Learning Research*, 24(253) :1–15.
- David Patterson, Joseph Gonzalez, Quoc Le, Chen Liang, Lluís-Miquel Munguia, Daniel Rothchild, David So, Maud Texier, and Jeff Dean. 2021. [Carbon Emissions and Large Neural Network Training](#).
- Emma Strubell, Ananya Ganesh, and Andrew McCallum. 2019. [Energy and Policy Considerations for Deep Learning in NLP](#). In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 3645–3650.
- Z. Zhang, W. You, T. Wu, X. Wang, J. Li, and M. Zhang. 2025. [A Survey of Generative Information Extraction](#). In *Proceedings of the 31st International Conference on Computational Linguistics (COLING)*, pages 4840–4870, Abu Dhabi, UAE.

A Expérimentations avec RoBERTa

Avant d’adopter l’approche par grands modèles de langage, nous avons testé une approche extractive basée sur RoBERTa réentraîné sur SQuAD v2. Le principe consiste à parcourir l’article avec une fenêtre glissante et à récupérer les segments de texte les plus pertinents pour chaque question.

Paramètres expérimentaux.

- Taille de fenêtre : 512 tokens
- Chevauchement : 128 tokens
- Longueur maximale de réponse : 20 tokens
- Nombre de candidats retenus : 10

Visualisation par carte de chaleur. Pour chaque token du document, nous avons calculé un score d’attention indiquant sa pertinence par rapport à la question posée. La figure ci-dessous illustre un extrait de cette carte de chaleur sur le papier BLOOM (Luccioni et al., 2023), pour la question “What is the name of the main machine learning model presented in this paper?”.

As reported in Table 1, training the BLOOM model required a total of 1.08 million GPU hours on a hardware partition constituted of Nvidia A100 SXM4 GPUs with 80GB of memory...

L’intensité de la couleur orange indique le score d’attention attribué par le modèle à chaque token. On observe que le mot “BLOOM” obtient le score maximal, ce qui est cohérent avec la question posée.

Segments candidats. Le tableau suivant présente les 10 meilleurs segments détectés :

Rang	Segment extrait	Score
1	Codecarbon	13.13
2	BLOOM	11.72
3	Open-access Multilingual Language Model	11.61
4	433,196 kWh	11.45
5	BLOOM model	10.71
6	1.08 million	10.82
7	TDP	10.60

TABLE 9 – Segments candidats détectés par RoBERTa pour la question sur le nom du modèle.

Limitations observées. Bien que les segments pertinents soient correctement identifiés, plusieurs problèmes limitent l’utilisabilité de cette approche :

- Les scores des bonnes réponses restent proches de ceux des mauvaises réponses, rendant la sélection automatique difficile.
- Le contexte limité à 512 tokens empêche de croiser des informations provenant de sections éloignées du document.
- Le modèle ne peut pas effectuer de raisonnement ou de calcul, contrairement aux LLM génératifs.

Ces limitations nous ont conduits à privilégier l’approche par grands modèles de langage décrite dans ce rapport.

B Schéma de la base de données

La figure 1 présente le schéma relationnel de la base de données utilisée pour stocker les informations extraites.




FIGURE 1 – Schéma relationnel. Trait plein : clé étrangère directe. Trait pointillé : référence via table de lookup.

Tables principales.

- **paper_info** : contient les métadonnées de chaque papier (lien, partition train/test)
- **model_info** : contient les informations sur chaque modèle mentionné dans un papier (vérité terrain)
- **paper_document** : stocke le contenu binaire du PDF téléchargé
- **paper_text** : stocke le texte extrait du PDF

Tables de référence.

- **country** : liste des pays avec leur intensité carbone (gCO_2/kWh), source Our World in Data
- **hardware** : liste des GPU/TPU avec leur puissance de calcul (FLOP/s) et consommation (kW), source Epoch.ai